



UNIVERZITET U NIŠU
ELEKTRONSKI FAKULTET

Katedra za računarstvo



ANALIZA KVALITETA PODATAKA KROZ VALIDACIJU, OPORAVAK I
MODELOVANJE

SEMINARSKI RAD

Predmet: Prikupljanje i predobrada podataka za mašinsko učenje

Student:

Nemanja Stojanović 2126

Mentor:

dr Aleksandar Stanimirović

Sadržaj

1. Uvod.....	2
2. Problem kvaliteta podataka	3
2.1 Dimenzije kvaliteta podataka	4
2.2 Formalna popunjenost i stvarna upotrebljivost	5
2.3 Uzroci problema i trošak nekvalitetnih podataka	5
3. Audit i analiza podataka	6
3.1 Raspodela podataka	6
3.2 Varijansa i mere rasipanja	7
3.3 Korelacija i međusobna konzistentnost	7
3.4 Mere kvaliteta i scorecard.....	8
3.5 Vizuelizacija	8
4. Nedostajuće vrednosti	9
4.1 Uklanjanje redova ili kolona	9
4.2 Jednostavna i grupna imputacija	9
4.3 Modelska i višestruka imputacija	10
4.4 Izbor strategije prema uslovima primene	10
4.5 Neizvesnost imputiranih vrednosti	11
5. Validacija i oporavak zasnovan na pravilima	11
5.1 Duplikati, konflikti i ekstremne vrednosti	12
5.2 Projektovanje i upravljanje pravilima validacije.....	12
5.3 Redosled intervencija.....	12
6. Indikatori kvaliteta, poreklo i nivo poverenja.....	13
6.1 Formiranje ocene poverenja	13
6.2 Poreklo podataka i reproduktivnost	14
7. Kvalitet podataka i mašinsko učenje	14
7.1 Izbor metrika	15
7.2 Uslovi fer poređenja i rizik curenja podataka	15
7.3 Kvalitet podataka, pristrasnost i pravičnost	15

7.4 Praćenje kvaliteta i promena distribucije	16
8. Prednosti, ograničenja i preporuke	16
9. Praktična demonstracija tehnika.....	17
9.1 Izbor skupova i početni audit	18
9.2 Primena oporavka nad transakcionim podacima	19
9.3 Baseline i rezultat regresionog eksperimenta	20
9.4 Primena validacije i imputacije nad kreditnim podacima.....	21
9.5 Baseline i rezultat klasifikacionog eksperimenta	22
9.6 Diskusija praktičnih rezultata.....	23
10. Zaključak	24
11. Literatura	24

1. Uvod

Podaci predstavljaju osnovu savremenog izveštavanja, odlučivanja i mašinskog učenja. Organizacije ih koriste za procenu rizika, planiranje resursa, praćenje poslovnih procesa i automatizaciju odluka. Međutim, pouzdanost rezultata neposredno zavisi od kvaliteta ulaznih podataka. Nedostajuće vrednosti, duplikati, nevalidne oznake, nelogični odnosi i zastarele informacije mogu dovesti do netačnih zaključaka i nepouzdanih odluka.

Kvalitet podataka ne može se proceniti samo brojem praznih ćelija. Vrednost može biti formalno prisutna, ali neupotrebljiva za analizu. Može imati odgovarajući tip, a ipak kršiti poslovno pravilo. Može biti tačna u trenutku prikupljanja, ali zastarela u trenutku upotrebe. Zbog toga se kvalitet posmatra kroz više dimenzija i u odnosu na konkretnu namenu podataka. Skup koji je pogodan za osnovno izveštavanje ne mora biti dovoljno pouzdan za procenu rizika ili automatsko donošenje odluka.

Predmet ovog rada su metode za identifikovanje, merenje i ublažavanje problema kvaliteta u strukturiranim podacima. Posebna pažnja posvećena je auditu, proveru potpunosti, validnosti i konzistentnosti, analizi raspodele, varijanse i korelacije, obradi nedostajućih vrednosti, oporavku zasnovanom na pravilima, kontrolisanoj imputaciji, odnosno popunjavanju nedostajućih vrednosti, i indikatorima kvaliteta.

U praktičnom delu, najpre se definiše baseline nad početnim podacima, a zatim se isti modelski zadatak ponavlja nakon obrade kvaliteta.

Opšti tok upravljanja kvalitetom podataka prikazan je na slici 1:



Slika 1: Tok upravljanja kvalitetom podataka

2. Problem kvaliteta podataka

Kvalitet podataka može se definisati kao stepen u kome su podaci pogodni za nameravanu upotrebu. Ovakva definicija naglašava kontekst. Na primer, približna lokacija može biti dovoljna za regionalnu statistiku, ali nedovoljna za dostavu. Mesečni prihod može biti dovoljan za izveštaj, ali ne i za dnevno planiranje zaliha.

Problemi nastaju u svim fazama životnog ciklusa. Pri prikupljanju se mogu javiti greške unosa, neujednačeni formati i izostavljene vrednosti. Pri integraciji izvora nastaju duplikati,

neusaglašene šifre i razlike u jedinicama mere. Tokom čuvanja i transformacije mogu se izgubiti informacije o poreklu, promeniti tipovi ili uvesti zaokruživanja. Nakon protoka vremena podaci mogu postati zastareli iako su prvobitno bili tačni.

Poseban problem predstavljaju skrivene greške. Standardna provera missing vrednosti neće pronaći tekstualne oznake kao što su **ERROR**, **UNKNOWN**, **N/A** ili **crtice** koje predstavljaju nedostajući podatak. Slično tome, broj može biti uspešno parsiran, ali nevalidan u domenskom kontekstu. Zbog toga tehnička ispravnost nije dovoljna, potrebna je i semantička validacija.

Posledice nekvalitetnih podataka obuhvataju:

- netačne poslovne izveštaje,
- smanjen broj upotrebljivih primera za modeliranje,
- učenje obrazaca koji potiču iz greške prikupljanja,
- nestabilne rezultate pri promeni izvora ili perioda,
- otežanu interpretaciju i nemogućnost revizije odluke,
- finansijski ili pravni rizik.

Kvalitet podataka zato nije samo tehničko pitanje predobrade. On utiče na validnost zaključka i odgovornost sistema koji podatke koristi.

2.1 Dimenzije kvaliteta podataka

Kvalitet se najčešće razlaže na dimenzije koje opisuju različite vrste zahteva. Najvažnije su **potpunost**, **tačnost**, **validnost**, **konzistentnost**, **jedinstvenost**, **pravovremenost** i **relevantnost**.

Potpunost pokazuje u kojoj meri su potrebne vrednosti prisutne u skupu podataka. Može se posmatrati na nivou pojedinačne ćelije, reda, kolone ili celog skupa. Najčešće se procenjuje poređenjem broja prisutnih vrednosti sa ukupnim brojem očekivanih vrednosti.

Tačnost označava slaganje podatka sa stvarnim stanjem. Za njeno merenje potreban je pouzdan referentni izvor, ponovljeno merenje ili potvrda stručnjaka. Tačnost je često najteža dimenzija za proveru jer skup sam po sebi ne mora sadržati dovoljno informacija da pokaže šta je istina.

Validnost proverava da li vrednost pripada dozvoljenom tipu, formatu, opsegu ili skupu kategorija. Datum mora odgovarati očekivanom formatu, količina mora biti nenegativna, a kategorijska vrednost mora pripadati definisanom domenu. Validnost se može proveravati šemama, regularnim izrazima, ograničenjima opsega i skupovima dozvoljenih vrednosti.

Konzistentnost označava slaganje vrednosti između kolona, tabela, izvora ili vremenskih preseka. Ako je jedna vrednost izvedena iz drugih, ona treba da bude u skladu sa poznatom formulom. Ako isti entitet postoji u više sistema, ključni atributi ne bi trebalo da budu međusobno protivrečni bez dokumentovanog razloga.

Jedinstvenost se odnosi na odsustvo neželjenih duplikata. Potpuno identični redovi mogu nastati ponovljenim uvozom, dok približni duplikati mogu sadržati manje razlike u zapisu imena ili adrese. Uklanjanje duplikata zahteva definiciju entiteta i poslovnog ključa. Dva jednaka reda nisu nužno duplikat ako predstavljaju dva legitimna događaja.

Pravovremenost opisuje da li su podaci dovoljno ažurni za zadatak. Relevantnost meri da li prikupljene kolone uopšte doprinose analizi. Ove dimenzije pokazuju zašto kvalitet ne može biti jedna univerzalna ocena: skup može biti kompletan, ali zastareo, ili validan, ali nerelevantan.

2.2 Formalna popunjenost i stvarna upotrebljivost

Formalna popunjenost znači da ćelija nije prazna. Stvarna upotrebljivost zahteva da vrednost ima odgovarajući tip i nivo pouzdanosti za konkretan zadatak. Tekstualni token UNKNOWN formalno popunjava ćeliju, ali se ne može koristiti kao stvarna kategorija ako samo označava da je podatak nepoznat. Numerička nula može biti validna vrednost ili kod za nedostajući podatak, u zavisnosti od dokumentacije.

Zbog toga je korisno pored standardne potpunosti računati i upotrebljivost:

$$\text{upotrebljivost} = \text{broj validnih i semantički prihvatljivih vrednosti} / \text{ukupan broj vrednosti}$$

Ova mera zahteva eksplicitnu definiciju pravila po koloni. Pravila treba čuvati kao deo dokumentacije, jer procenat bez objašnjenja šta se smatra upotrebljivim nije reproduktivan.

2.3 Uzroci problema i trošak nekvalitetnih podataka

Problemi kvaliteta obično nisu izolovane slučajne greške, već posledica načina na koji je sistem projektovan. Ako je unos obavezan samo u jednom korisničkom interfejsu, podaci pristigli iz drugog kanala mogu imati drugačiju stopu nedostajućih vrednosti. Ako više sistema koristi različite šifre za isti pojam, integracija stvara prividne nove kategorije. Ako se jedinica mere promeni bez verzionisanja, raspodela atributa može naglo da se pomeri iako se stvarni proces nije promenio.

Uzroke je korisno podeliti na nekoliko grupa:

- ljudske greške pri unosu, izboru kategorije ili tumačenju polja,
- tehničke greške senzora, mreže ili parsera
- neusaglašene šeme i jedinice mere između izvora,
- promene poslovnog procesa koje nisu prenete u pravila validacije,
- zastarevanje podataka tokom vremena,
- greške nastale agregacijom, spajanjem i višestrukim transformacijama.

Pronalaženje korenskog uzroka važnije je od ponovnog popravljavanja posledice. Ako se ista nevalidna kategorija pojavljuje svakog dana, čišćenje u analitičkom sloju rešava samo trenutni skup. Ispravka validacije na mestu unosa sprečava nastanak novih grešaka. Zbog toga se upravljanje kvalitetom deli na preventivne i korektivne mere. Preventivne mere uključuju šeme, obavezna polja, padajuće liste, referencijalni integritet i automatske provere pri unosu. Korektivne mere obuhvataju standardizaciju, imputaciju, deduplikaciju i oporavak već prikupljenih podataka.

Trošak lošeg kvaliteta može biti direktan i indirektan. Direktni trošak obuhvata ručnu proveru, ponovljeno prikupljanje i reklamacije. Indirektni trošak nastaje kroz pogrešne odluke, propuštene prilike, nestabilne modele i gubitak poverenja korisnika. Nije racionalno težiti apsolutnoj savršenosti svake kolone. Prioritet treba dati greškama koje utiču na ključne odluke i nose najveći rizik.

3. Audit i analiza podataka

Audit je sistematičan pregled stanja skupa pre intervencije. Njegova svrha nije samo pronalaženje grešaka, već formiranje merljivog početnog stanja koje će kasnije služiti kao referenca. Audit treba izvršiti pre čišćenja, sačuvati rezultate i ponoviti nakon obrade.

Osnovni audit obuhvata broj redova i kolona, tipove atributa, nedostajuće vrednosti, jedinstvene vrednosti, duplikate i osnovne deskriptivne statistike. Za kategorijske kolone proveravaju se frekvencije, retke kategorije i nevalidni tokeni. Za numeričke kolone proveravaju se minimum, maksimum, srednja vrednost, medijana, varijansa i ekstremne vrednosti. Za datume se proveravaju opseg i hronološka konzistentnost.

Analizu je korisno automatizovati, ali automatski izveštaj nije zamena za domensko razumevanje. Alat može pokazati da je vrednost retka, ali ne može uvek zaključiti da li je retkost greška ili legitimna pojava. Najbolji rezultat daje kombinacija automatskih provera, vizuelizacije i poslovnih pravila.

Audit treba da odgovori na sledeća pitanja:

- koje kolone su ključne za zadatak?
- koje vrednosti nedostaju?
- da li tipovi odgovaraju semantici atributa?
- postoje li nelogični opsezi ili odnosi?
- koliko redova je pogođeno svakim problemom?

3.1 Raspodela podataka

Raspodela opisuje kako su vrednosti raspoređene u domenu atributa. Histogram, kernel procena gustine, empirijska kumulativna raspodela i boxplot omogućavaju da se vide asimetrija, višemodalnost, repovi i ekstremne vrednosti. Kategorijske raspodele prikazuju se frekvencijama ili relativnim udelima.

Oblik raspodele utiče na izbor metode obrade. Kod približno simetrične raspodele srednja vrednost može biti reprezentativna, dok je kod asimetrične raspodele medijana otpornija.

Višemodalna raspodela može ukazivati na mešanje različitih grupa, pa jedna globalna imputaciona vrednost nije primerena. Ekstremna vrednost može biti greška, ali i važan redak slučaj. Odluka zahteva domensko pravilo.

Raspodelu treba porediti pre i posle obrade. Ako imputacija stvori veliki veštački vrh na jednoj vrednosti ili uklanjanje redova promeni udeo važne grupe, tehnička kompletnost je možda povećana uz gubitak statističke verodostojnosti.

3.2 Varijansa i mere rasipanja

Varijansa meri prosečno kvadratno odstupanje od srednje vrednosti, dok standardna devijacija predstavlja njen koren i izražena je u istoj jedinici kao atribut. Koeficijent varijacije omogućava relativno poređenje rasipanja kada su srednje vrednosti pozitivne i različitog reda veličine.

Veoma mala varijansa može označiti atribut sa malo informacije za model, ali i posledicu nekritičke imputacije. Naglo povećanje varijanse može ukazivati na greške jedinice mere ili ekstremne vrednosti. Promena varijanse nakon obrade zato je važna kontrola: cilj nije samo ukloniti missing oznake, već očuvati realnu strukturu podataka.

3.3 Korelacija i međusobna konzistentnost

Korelacija opisuje statističku povezanost atributa. Pearsonov koeficijent meri linearnu povezanost numeričkih promenljivih, dok je Spearmanova korelacija pogodnija za monotone odnose i manje osetljiva na ekstremne vrednosti. Za kategorijske attribute koriste se druge mere, kao što su hi-kvadrat test i Cramér-ov V.

Korelacija može pomoći u otkrivanju problema. Neočekivano slaba veza između veličina koje su povezane formulom može ukazivati na nevalidne vrednosti. Neočekivano visoka korelacija može pokazati dupliranu informaciju ili curenje ciljne promenljive. Međutim, korelacija ne dokazuje uzročnost i ne treba je koristiti kao jedini kriterijum za popravku podataka.

Konzistentnost se može preciznije proveriti kada između atributa postoji poznato poslovno ili aritmetičko pravilo. U tom slučaju iz jednih vrednosti može se izračunati očekivana vrednost druge i zatim proveriti da li se ona slaže sa podatkom u skupu. Manja odstupanja ne moraju automatski predstavljati grešku, jer mogu nastati usled zaokruživanja, poreza, popusta ili drugih pravila specifičnih za posmatrani domen.

3.4 Mere kvaliteta i scorecard

Audit proizvodi veliki broj pojedinačnih nalaza, pa je korisno organizovati ih u scorecard. Scorecard je tabela ili skup pokazatelja koji za svaku kolonu i dimenziju prikazuje trenutno stanje, ciljnu vrednost i promenu kroz vreme.

Njegova svrha nije da sakrije složenost jednom ocenom, već da omogući poređenje i prioritizaciju.

Za kolonu se mogu računati:

- procenat formalno prisutnih vrednosti,
- procenat upotrebljivih vrednosti,
- procenat vrednosti koje pripadaju dozvoljenom domenu,
- broj i ideo aritmetičkih ili logičkih konflikata,
- broj jedinstvenih vrednosti,
- procenat duplikata prema definisanom ključu,
- procenat vrednosti koje su ažurirane ili oporavljene.

Moguće je formirati ukupnu ocenu kvaliteta povezivanjem više pojedinačnih pokazatelja, pri čemu se važnijim dimenzijama dodeljuje veći značaj. Na primer, potpunost identifikatora može biti važnija od popunjenosti opcionog komentara. Ukupnu ocenu ipak treba prikazivati zajedno sa pojedinačnim pokazateljima, jer isti rezultat može biti posledica različitih problema u podacima.

Pragovi kvaliteta treba da budu dogovoreni sa vlasnikom podataka. Na primer, kritična kolona može zahtevati najmanje 99% validnih vrednosti, dok je za opciono polje prihvatljiv niži prag. Prag nije statistička univerzalna konstanta, on zavisi od posledice greške, mogućnosti ručne provere i troška prikupljanja.

Scorecard dobija najveću vrednost kada se prati kroz vreme. Jednokratni audit pokazuje stanje, ali vremenska serija pokazuje trend, sezonski obrazac i naglu regresiju nakon promene sistema. Uz metriku treba čuvati verziju šeme, izvor, period i broj posmatranih redova kako bi poređenje bilo ispravno.

3.5 Vizuelizacija

Vizuelizacija ubrzava pronalaženje obrazaca koji se teško vide u tabeli. Matrica nedostajućih vrednosti pokazuje da li polja izostaju zajedno. Histogrami i boxplot prikazi otkrivaju asimetriju i ekstremne vrednosti. Stubičasti grafikoni kategorija ukazuju na nove ili neuobičajene oznake. Scatter plot povezanih atributa pokazuje zapise koji odstupaju od očekivane veze.

Grafikon mora prikazivati broj primera i odgovarajuću skalu. Relativni procenat bez apsolutnog broja može preuveličati problem u maloj grupi, dok ukupni broj može sakriti visoku stopu greške u retkoj grupi. Vizuelni nalaz je početak istrage, a ne automatski dokaz da zapis treba izmeniti.

4. Nedostajuće vrednosti

Nedostajuća vrednost može nastati zato što podatak nije prikupljen, nije primenljiv, izgubljen je tokom prenosa ili nije prošao validaciju. Razlog izostanka utiče na opravdanost metode obrade. U statistici se razlikuju MCAR, MAR i MNAR mehanizmi.

Kod MCAR mehanizma verovatnoća izostanka ne zavisi ni od posmatranih ni od nepoznatih vrednosti. Kod MAR mehanizma izostanak zavisi od drugih posmatranih atributa, pa se oni mogu koristiti pri imputaciji. Kod MNAR mehanizma izostanak zavisi od same nepoznate vrednosti ili neprikupljenog faktora, tada standardna imputacija može zadržati ili povećati pristrasnost.

U praksi se mehanizam retko može dokazati samo iz podataka. Potrebno je poznavanje procesa prikupljanja, analiza obrazaca izostanka i poređenje grupa sa prisutnim i odsutnim vrednostima.

4.1 Uklanjanje redova ili kolona

Uklanjanje je najjednostavnije rešenje. Opravdano je kada je broj pogođenih redova mali, kada su izostanci približno slučajni i kada brisanje ne menja važne raspodele. Kolona se može ukloniti ako je uglavnom prazna, nepouzdana ili nerelevantna za zadatak.

Prednost je što se ne uvode procenjene vrednosti. Nedostatak je gubitak informacija i mogućnost selekcione pristrasnosti. Ako određena grupa češće ima nedostajuće vrednosti, njeno uklanjanje menja populaciju nad kojom model uči.

4.2 Jednostavna i grupna imputacija

Jednostavna imputacija koristi srednju vrednost, medijanu, modus ili posebnu kategoriju. Medijana je često pogodna za asimetrične numeričke raspodele, a modus za stabilne kategorijske

atribute. Posebna kategorija „nepoznato“ čuva činjenicu da podatak nije dostupan, ali ne sme se predstavljati kao stvarno poznata vrednost.

Grupna imputacija procenjuje vrednost unutar relevantne grupe. Ako atribut zavisi od regiona, razreda rizika, starosne grupe ili tipa proizvoda, grupna medijana može bolje očuvati heterogenost od globalne. Uslov je da grupa ima dovoljno primera i da nije definisana informacijom koja u trenutku predikcije nije dostupna.

Prednost ovih metoda je jednostavnost, stabilnost i laka primena unutar pipeline-a. Nedostaci su smanjenje varijanse, potcenjivanje neizvesnosti i mogućnost stvaranja nerealnih kombinacija. Imputirana vrednost nije povraćena činjenica, već procena.

4.3 Modelska i višestruka imputacija

Složeniji pristupi predviđaju nedostajuću vrednost pomoću drugih atributa. K-nearest neighbours koristi slične zapise, iterativna imputacija modeluje svaku problematičnu kolonu pomoću ostalih, a višestruka imputacija generiše više mogućih skupova kako bi uključila neizvesnost.

Ove metode mogu očuvati složenije odnose, ali zahtevaju dovoljno podataka, pažljivo podešavanje i veću računarsku cenu. Postoji rizik curenja informacija ako se imputacioni model uči pre podele podataka. Zato se parametri imputacije moraju učiti isključivo na trening skupu i zatim primeniti na validacioni i test skup.

4.4 Izbor strategije prema uslovima primene

Strategija se ne bira samo prema procentu missing vrednosti. Potrebno je razmotriti ulogu kolone, mehanizam izostanka, količinu podataka, oblik raspodele i osetljivost zadatka. Za atribut koji direktno definiše cilj imputacija može biti neprihvatljiva, dok je za pomoćni atribut sa malim udelom slučajnih izostanaka medijana često dovoljna.

Uklanjanje redova ima smisla kada je udeo mali i kada analiza pokaže da izostanak nije koncentrisan u određenoj grupi. Jednostavna imputacija je primerena za stabilan baseline i velike skupove sa umerenim udelom problema. Grupna imputacija ima smisla kada postoji jaka, domenski opravdana veza sa grupom. Modelska imputacija opravdana je kada su međusobni odnosi složeni i kada postoji dovoljno podataka za proveru greške imputacionog modela. Rule-based oporavak ima prednost kada je vrednost deterministički izvediva.

Posebnu pažnju zahtevaju kategorijske vrednosti. Dodavanje kategorije „nepoznato“ često je transparentnije od popunjavanja najčešćom kategorijom, jer modus stvara privid da je identitet poznat. Sa druge strane, ako missing nastaje nasumično i procenat je veoma mali, posebna

kategorija može nepotrebno povećati dimenzionalnost. Odluka zavisi od procesa prikupljanja i ponašanja modela.

Izbor treba proveriti analizom osetljivosti. Mogu se uporediti brisanje, medijana, grupna medijana i modelska imputacija uz istu podelu. Pored performansi modela posmatraju se raspodela imputiranog atributa, varijansa, korelacije i razlike između grupa. Ako složenija metoda ne daje stabilnu korist, jednostavnija je obično bolji izbor zbog reproduktivnosti.

4.5 Neizvesnost imputiranih vrednosti

Jedna popunjena vrednost često stvara lažan utisak sigurnosti. Ako je medijana 10, to ne znači da je stvarna nepoznata vrednost bila 10. Kod izveštavanja treba razlikovati originalne, imputirane i oporavljene vrednosti. Kada odluka zavisi od pojedinačnog zapisa, preporučljivo je čuvati i interval ili meru pouzdanosti.

Višestruka imputacija upravo zato generiše više mogućih verzija i kombinuje rezultate. U mašinskom učenju slična ideja može se primeniti treniranjem modela na više imputiranih uzoraka ili poređenjem predikcije kroz scenarije. Ako se odluka znatno menja zavisno od imputacije, sistem treba da označi slučaj za dodatnu proveru.

5. Validacija i oporavak zasnovan na pravilima

Validacija proverava tip, domen i odnose između atributa. Pravila mogu biti sintaksna, semantička, aritmetička, vremenska i referencijalna. Primeri su dozvoljen opseg starosti, usklađenost radnog staža sa starošću, postojanje šifre u referentnoj tabeli ili slaganje ukupnog iznosa sa količinom i cenom.

Rule-based oporavak koristi takva pravila ne samo za otkrivanje problema već i za rekonstrukciju vrednosti. Ako je veza deterministička i poznate komponente su pouzdane, nepoznata komponenta može se izvesti. Oporavak se razlikuje od imputacije: cilj je rekonstruisati vrednost iz konkretnog zapisa ili potvrđenog domenskog pravila, a ne zameniti je tipičnom procenom populacije.

Opravdana primena zahteva:

- stabilno i dokumentovano poslovno pravilo,
- pouzdane ulazne vrednosti od kojih se rezultat izvodi,
- toleranciju za zaokruživanje i legitimne izuzetke,
- dovoljan broj validnih primera za proveru pravila,
- evidentiranje svake promene i razloga oporavka.

Prednosti su interpretabilnost, mogućnost revizije i očuvanje redova koji bi inače bili odbačeni. Nedostaci su zavisnost od domena, krhkost pri promeni poslovnog procesa i rizik da se pogrešno pravilo sistematski primeni na veliki broj zapisa. Zato pravila treba verzionisati i pratiti njihovu stopu aktiviranja.

5.1 Duplikati, konflikti i ekstremne vrednosti

Duplikat treba definisati u odnosu na entitet ili događaj. Potpuno isti zapisi nisu automatski greška ako dve legitimne transakcije imaju iste atribute. Pouzdanije je koristiti primarni ključ, vremensku oznaku i domenske atribute. Kod približnih duplikata koriste se normalizacija teksta, sličnost i probabilističko povezivanje zapisa.

Konflikt nastaje kada više izvora ili kolona daju različite vrednosti za istu činjenicu. Rešenje može biti izbor autoritativnog izvora, pravilo prioriteta, najnovija vrednost ili označavanje konflikta bez automatskog razrešenja.

Ekstremne vrednosti mogu se otkrivati IQR pravilom, z-score merom, robustnim merama ili modelima anomalija. Statistička neobičnost nije isto što i greška. Pre uklanjanja potrebno je proveriti jedinicu mere, poslovni kontekst i uticaj na zadatak.

5.2 Projektovanje i upravljanje pravilima validacije

Pravilo kvaliteta treba da ima naziv, opis, vlasnika, kolone na koje se odnosi, nivo ozbiljnosti i očekivanu akciju. Neka pravila samo upozoravaju, dok druga sprečavaju unos ili izdvajaju zapis iz automatske obrade. Razdvajanje nivoa ozbiljnosti sprečava da svaki neobičan podatak bude tretiran kao kritična greška.

Pravila mogu biti tvrda i meka. Tvrdo pravilo predstavlja uslov koji ne bi smeo imati legitimne izuzetke, kao što je referenca na nepostojeći identifikator. Meko pravilo označava sumnjiv obrazac, na primer neuobičajeno visok iznos. Meko pravilo zahteva ručnu proveru ili dodatni kontekst i ne treba automatski da menja vrednost.

Svako pravilo treba testirati na istorijskim podacima. Ako označava preveliki broj legitimnih zapisa, prag ili definicija nisu odgovarajući. Ako gotovo nikada ne reaguje, moguće je da je suviše široko ili više nije relevantno. Stopa aktiviranja i udeo potvrđenih grešaka predstavljaju metrike kvaliteta samog pravila.

Poslovni procesi se menjaju, pa pravila moraju biti verzionisana. Promena cenovnika, valute, starosne granice ili načina obračuna može učiniti staro pravilo pogrešnim. Uz svaki obrađeni zapis treba moći utvrditi koja verzija pravila je primenjena.

5.3 Redosled intervencija

Redosled koraka utiče na rezultat. Standardizacija missing tokena treba da prethodi računanju potpunosti. Parsiranje tipova treba izvršiti pre provere numeričkog opsega. Deduplikacija može prethoditi učenju imputacionih statistika, jer bi duplikati u suprotnom promenili medijanu ili frekvenciju. Oporavak izvedenih vrednosti treba raditi tek nakon potvrde pouzdanosti ulaznih komponenti.

Pipeline treba da bude deterministički i idempotentan: ponovno pokretanje nad već obrađenim podacima ne bi trebalo da menja vrednosti. To se postiže jasnim oznakama verzije, odvajanjem sirovih i obrađenih tabela i testovima za svaku transformaciju.

6. Indikatori kvaliteta, poreklo i nivo poverenja

Nakon obrade skup može izgledati potpuno uredno, iako deo vrednosti više nije originalan. Zbog toga je važno čuvati poreklo. Quality flag je binarni ili kategorijski atribut koji označava da je vrednost nedostajala, bila konfliktna, imputirana ili oporavljena. Zbirni broj problema daje pregled opterećenja reda, dok nivo poverenja grupiše zapise prema kvalitetu ključnih atributa.

Indikatori omogućavaju audit, filtriranje i analizu osetljivosti. Strogi izveštaj može koristiti samo zapise visokog poverenja, dok šira deskriptivna analiza može uključiti i srednji nivo. U modelu flag može preneti informaciju da je vrednost procenjena. Ipak, on može postati proxy za osetljivu grupu ili proces prikupljanja, pa njegov uticaj treba analizirati.

Dobro upravljanje poreklom podrazumeva čuvanje originalne vrednosti, nove vrednosti, pravila, vremena intervencije i verzije koda. Time se omogućavaju reproduktivnost i povratak na početno stanje.

6.1 Formiranje ocene poverenja

Ocena poverenja može se formirati pravilima ili probabilističkim modelom. Jednostavan pristup dodeljuje poene za prisustvo ključnih polja, prolazak validacionih pravila i slaganje sa referentnim izvorom, a oduzima poene za imputaciju, konflikt i zastarelost. Rezultat se zatim mapira na visok, srednji ili nizak nivo.

Težine moraju biti povezane sa namenom. Nedostajući kontakt može biti kritičan za operativni proces, ali nevažan za agregatnu statistiku prodaje. Zbog toga isti zapis može imati različit nivo poverenja za različite zadatke. Univerzalni trust score bez konteksta lako stvara pogrešnu sigurnost.

Ocenu treba kalibrisati na ručno proverenom uzorku. Ako zapisi visokog poverenja često sadrže greške, definicija nije dobra. Takođe treba pratiti pokrivenost: veoma stroga pravila mogu proizvesti mali, čist skup koji više nije reprezentativan za populaciju.

6.2 Poreklo podataka i reproduktivnost

Poreklo opisuje put podatka od izvora do konačne tabele. Obuhvata izvorni sistem, transformacije, spajanja, filtriranje i verzije pravila. Bez porekla nije moguće pouzdano objasniti zašto se vrednost promenila ili ponoviti analizu nakon ažuriranja.

Praktično rešenje je slojevita arhitektura: sirovi sloj ostaje neizmenjen, očišćeni sloj sadrži standardizovane vrednosti, a analitički sloj izvedene attribute. Identifikator reda povezuje slojeve. Dnevnik popravki treba da sadrži staru i novu vrednost, razlog, pouzdanost i vreme promene.

Reproduktivnost zahteva i verzionisanje koda, konfiguracije i slučajnih semena. Isti ulaz i ista verzija pipeline-a treba da daju isti izlaz. To je posebno važno kada modelske metrike služe kao dokaz efekta tehnike kvaliteta.

7. Kvalitet podataka i mašinsko učenje

Model uči statističke obrasce iz dostupnih primera. Nedostajuće i nevalidne vrednosti mogu smanjiti broj primera, promeniti raspodelu atributa ili stvoriti lažne korelacije. Duplikati mogu dovesti do toga da isti ili gotovo isti zapis završi u trening i test skupu. Neadekvatna imputacija može veštački smanjiti varijansu, dok obrada izvedena nad svim podacima može izazvati curenje informacija.

Efekat tehnike kvaliteta treba proveravati kontrolisanim eksperimentom. Minimalni postupak obuhvata:

1. definisanje zadatka i metrike,
2. formiranje nepromenljivog test skupa,
3. uspostavljanje baseline pipeline-a nad početnom verzijom podataka,
4. primenu tehnike kvaliteta bez korišćenja test ciljeva,
5. ponavljanje modela uz istu podelu i iste hiperparametre,
6. poređenje metrike, stabilnosti, kompletnosti i interpretabilnosti.

Baseline treba da bude dovoljno jednostavan da predstavlja jasnu referencu. On može označavati osnovni algoritam, ali u istraživanju kvaliteta podataka važnija je početna verzija skupa: isti model nad podacima pre intervencije. Ako se istovremeno promene podaci, algoritam i hiperparametri, nije moguće utvrditi uzrok poboljšanja.

7.1 Izbor metrika

Kod regresije se često koriste MAE, RMSE i koeficijent determinacije R^2 . MAE izražava prosečnu apsolutnu grešku i lako se tumači u jedinici ciljne promenljive. RMSE jače kažnjava velike greške. R^2 opisuje deo varijanse cilja objašnjen modelom, ali može biti negativan kada je model slabiji od konstantne procene.

Kod klasifikacije accuracy nije dovoljna kada su klase neuravnotežene ili imaju različite posledice greške. Precision meri udeo tačnih pozitivnih predikcija, recall udeo pronađenih pozitivnih primera, a F1 njihovu harmonijsku sredinu. Balanced accuracy i macro F1 daju veću težinu manjinskoj klasi, dok ROC AUC ocenjuje rangiranje kroz različite pragove.

Pored modelskih metrika treba posmatrati i podatkovne metrike: promenu upotrebljivosti, broj oporavljenih redova, raspodelu, varijansu i aktiviranje flagova. Bolja modelska metrika nije dovoljna ako je postignuta curenjem ili gubitkom važnih grupa.

7.2 Uslovi fer poređenja i rizik curenja podataka

Train/test podela mora biti ista za baseline i obrađenu verziju. Imputeri, skaleri, cenovnici izvedeni iz uzorka i druge naučene transformacije treba da koriste samo trening podatke kada mogu preneti informaciju iz testa. Ako se predviđaju budući događaji, podela treba da bude vremenska, a ne slučajna.

Preporučljivo je koristiti unakrsnu validaciju ili više ponovljenih podela, naročito kada je skup mali. Razliku u metrici treba tumačiti zajedno sa njenom varijabilnošću. Minimalan pomak na jednom preseku nije nužno dokaz stvarnog poboljšanja.

7.3 Kvalitet podataka, pristrasnost i pravičnost

Problemi kvaliteta često nisu ravnomerno raspoređeni. Jedna grupa može češće imati nedostajuće vrednosti zbog slabijeg pristupa digitalnim kanalima, druga zbog drugačijeg načina prikupljanja. Ako se redovi sa missing vrednostima obrišu, grupa može biti nedovoljno zastupljena. Ako se svi imputiraju globalnim prosekom, njene specifične osobine mogu biti izbrisane.

Zato podatkovne metrike treba računati i po relevantnim podgrupama. Ukupna potpunost od 98% može sakriti potpunost od 80% u maloj, ali važnoj grupi. Isto važi za stopu konflikata, duplikata, oporavka i grešku modela. Analiza podgrupa mora poštovati privatnost i koristiti samo opravdane attribute.

Quality flag može pomoći modelu, ali može postati proxy za izvor, region ili socioekonomsku grupu. Poboljšanje ukupnog F1 ne opravdava atribut ako povećava nejednakost greške. Potrebno je porediti precision, recall i kalibraciju između grupa, kao i proveriti da li intervencija menja njihovu zastupljenost.

Pravičnost ne znači automatsko uklanjanje svih osetljivih atributa. Ponekad su oni potrebni upravo za merenje razlike. Važno je razdvojiti njihovu ulogu u auditu od uloge u predikciji i dokumentovati pravni i etički osnov primene.

7.4 Praćenje kvaliteta i promena distribucije

Kvalitet nije završen kada se model obuči. Novi izvori, izmene korisničkog interfejsa i promene poslovnih pravila mogu promeniti stopu missing vrednosti i raspodelu atributa. Sistem koji ne prati ulazne podatke može nastaviti da daje predikcije iako više ne prima podatke slične trening skupu.

Praćenje treba da obuhvati obim podataka, šemu, udeo missing i nevalidnih vrednosti, nove kategorije, varijanse i korelacija, kao i aktiviranje pravila kvaliteta. Za poređenje distribucija mogu se koristiti Population Stability Index, Kolmogorov-Smirnov test ili druge mere udaljenosti, uz pažljivo tumačenje veličine uzorka.

Alarm treba povezati sa akcijom. Nagla pojava nove kategorije može zahtevati ažuriranje encoder-a, porast nedostajućih vrednosti, promena aritmetičke veze ili reviziju poslovnog pravila. Nije svaka promena kvar, sezonski obrazac može biti legitiman pa je potreban vlasnik koji tumači upozorenje.

Kada naknadno postanu dostupne stvarne ciljne vrednosti, prati se i modelska performansa. Data drift ne mora obavezno smanjiti kvalitet modela, dok concept drift može nastati i bez velike promene marginalnih raspodela. Zato se podatkovni i modelski monitoring dopunjuju.

8. Prednosti, ograničenja i preporuke

Prednost sistematskog pristupa je u njegovoj transparentnosti. Audit omogućava da se problem precizno kvantifikuje, pravila jasno opisuju primenjenu intervenciju, dok poređenje sa početnim stanjem pokazuje njene posledice. Zadržavanjem oznaka (flagova) ostaje vidljivo poreklo vrednosti, a kontrolisana obrada omogućava očuvanje većeg broja korisnih redova u odnosu na njihovo potpuno brisanje.

Ograničenje je to što nijedna tehnika nije univerzalna. Imputacija može smanjiti varijansu i sakriti MNAR obrazac. Rule-based oporavak može preneti pogrešno ili zastarelo pravilo.

Uklanjanje duplikata može obrisati legitimne događaje. Quality flag može postati neželjeni proxy. Modelsko poboljšanje može biti malo kada je baseline već jak ili kada problematični atributi nisu presudni za cilj.

Izbor rešenja može se sažeti kroz odnos osnove, uslova i rizika. Brisanje se zasniva na pretpostavci da je gubitak redova prihvatljiv. Grupna imputacija na pretpostavci da grupa objašnjava deo raspodele. Modelska imputacija na stabilnosti odnosa među atributima. Rule-based oporavak na determinističkoj domenskoj vezi. Flag-ovi na pretpostavci da je poreklo vrednosti važno za analizu. Kada osnovna pretpostavka nije ispunjena, metod može proizvesti uredniji, ali manje istinit skup.

Rešenje treba birati prema posledici greške. Kod agregatnog izveštaja mala imputaciona greška može imati zanemarljiv uticaj. Kod odluke o pojedincu ista greška može biti neprihvatljiva. U visoko rizičnim domenima automatska popravka treba da bude konzervativna, uz ljudsku proveru i mogućnost povratka na originalnu vrednost.

Složenost takođe ima cenu. Napredna imputacija ili model za otkrivanje anomalija zahtevaju održavanje, ponovno treniranje i nadzor. Ako jednostavna medijana unutar domenski opravdane grupe daje isti rezultat, složeniji pristup ne donosi dovoljno vrednosti. Prednost treba dati najjednostavnijoj metodi koja zadovoljava zahteve kvaliteta i prolazi empirijsku proveru.

Važno je razlikovati uspeh obrade na nivou podataka i uspeh na nivou modela. Povećanje potpunosti sa 95% na 100% ne mora poboljšati predikciju, a mala modelska promena ne znači da je obrada bezvredna. Intervencija može olakšati izveštavanje, smanjiti broj ručnih grešaka, poboljšati reviziju i sprečiti buduće kvarove. Procena treba da uključi tehničke, statističke, poslovne i etičke kriterijume.

Preporuke su:

- početi od namene podataka i ključnih atributa,
- sačuvati neizmenjeni izvor i jedinstvene identifikatore,
- proveriti nedostajuće vrednosti i duplikate,
- meriti raspodelu, varijansu i odnose pre i posle obrade,
- dati prednost determinističkom oporavku samo kada je pravilo proverljivo,
- koristiti grupnu imputaciju kada grupe imaju domensko opravdanje,
- čuvati flagove i dnevnik intervencija,
- porediti isti model i istu podelu sa baseline verzijom,
- pratiti promenu kvaliteta i nakon puštanja sistema u rad.

9. Praktična demonstracija tehnika

Praktična demonstracija realizovana je u notebook-u “*kvalitet-podataka.ipynb*”. Izabrana su dva skupa podataka zato što predstavljaju različite situacije: transakcione podatke sa determinističkim odnosima pogodnim za oporavak i kreditne podatke pogodne za validaciju, grupnu imputaciju i označavanje kvaliteta. Nazivi skupova i atributa u nastavku služe isključivo za prikaz primene prethodno objašnjenih metoda.

9.1 Izbor skupova i početni audit

Cafe Sales sadrži transakcije sa artiklom, količinom, cenom, ukupnim iznosom, datumom, lokacijom i načinom plaćanja. Eksplicitne oznake ERROR i UNKNOWN i aritmetička veza između količine, cene i iznosa čine skup pogodnim za demonstraciju formalne popunjenosti, stvarne upotrebljivosti i rule-based oporavka.


Credit Risk sadrži demografske i kreditne atribute, uključujući prihod, radni staž, iznos i namenu kredita, kreditnu klasu, kamatnu stopu i ciljnu promenljivu “**loan_status**”. Nedostajuće vrednosti, duplikati i odnosi između starosti, radnog staža, kreditne istorije, kredita i prihoda omogućavaju demonstraciju validacije, imputacije i quality flagova.

Početni audit oba skupa prikazan je na slici 2.

	dataset	columns_with_missing	max_missing_pct	identifier_columns	target_columns
0	Cafe Sales	7	32.65	Transaction ID	
1	Credit Risk	2	9.56		loan_status

Slika 2: Inicijalni audit Cafe Sales i Credit Risk skupova podataka

Procenat upotrebljivih kolona i problematičnih vrednosti prikazan je na slici 3:




Slika 3: Procenat upotrebljivih kolona i problematičnih vrednosti

9.2 Primena oporavka nad transakcionim podacima


Najpre je iz validnih redova izveden cenovnik po artiklu. Cena je oporavljena kada je artikal poznat i cenovnik stabilan. Ukupan iznos se izračunava iz količine i cene. Količina iz iznosa i cene.

Svaka intervencija evidentirana je u repair log-u, a redovima su dodati broj oporavljenih polja i “**trust_tier**”. Time praktični deo primenjuje teorijske principe proverljivog pravila, porekla vrednosti i nivoa poverenja.



Slika 4: Rule-based oporavak: cenovnik, oporavak cene, ukupnog iznosa i količine

Na slici 5 prikazana je upotrebljivost transakcionih kolona pre i posle oporavka:




Slika 5: Upotrebljivost transakcionih kolona pre i posle oporavka

9.3 Baseline i rezultat regresionog eksperimenta

Zadatak modela je predviđanje dnevne potražnje za svaki artikal. Baseline koristi početne agregirane podatke, dok unapređena verzija koristi obrađene agregate. Podela podataka na trening i test skup, ciljna promenljiva i konfiguracija modela ostaju nepromenjeni. Glavna metrika za procenu uspešnosti je MAE.

Poređeni su Ridge, Random Forest, Extra Trees, HistGradientBoosting, XGBoost, LightGBM i CatBoost. CatBoost se poboljšao sa MAE 3,6328 na 3,3571, Random Forest sa 3,6653 na 3,3619, Extra Trees sa 3,8007 na 3,3810, a XGBoost sa 4,0291 na 3,5356. Najveće apsolutno smanjenje MAE među prikazanim modelima ostvario je XGBoost, dok je najbolju završnu MAE vrednost ostvario CatBoost, kao što je prikazano na slici 6:




Slika 6: MAE regresionih modela nad početnim i oporavljenim podacima

9.4 Primena validacije i imputacije nad kreditnim podacima

U drugom skupu uklonjeni su potvrđeni duplikati, a nedostajuća kamatna stopa imputirana je medianom u okviru kreditne klase. Radni staž imputiran je prema starosnoj grupi, uz globalnu rezervnu medianu kada grupa nema dovoljno podataka. Izvedeni odnos iznosa kredita i prihoda ponovo je izračunat iz osnovnih atributa.


Uvedeni su flagovi za nedostajuće, imputirane i logički sumnjive vrednosti, kao i zbirni broj problema. Na taj način očišćen skup ne prikriva činjenicu da je nad pojedinim redovima izvršena intervencija.

Na slici 7 prikazana je evidencija izvršenih intervencija:



Slika 7: Evidencija izvršenih intervencija

Dok je na slici 8 prikazan odnos indikatora kvaliteta i stope rizične klase:




Slika 8: Odnos indikatora kvaliteta i stope rizične klase

9.5 Baseline i rezultat klasifikacionog eksperimenta

Cilj je predikcija “**loan_status**”, pri čemu pozitivna klasa predstavlja rizičan ishod, “**raw_baseline**” koristi početne vrednosti uz minimalnu imputaciju potrebnu da pipeline radi. Zatim se porede “**cleaned**” i “**cleaned_quality_flags**” verzije nad istim zadržanim redovima i istom podelom. Glavna metrika je F1 pozitivne klase, uz accuracy, balanced accuracy, macro F1, precision, recall i ROC AUC.

Poređeni su Logistic Regression, Random Forest, Extra Trees, HistGradientBoosting, XGBoost, LightGBM i CatBoost. Najbolji rezultat ostvario je LightGBM: F1 rizične klase raste sa 0,840 u baseline verziji na 0,841 nakon čišćenja i 0,845 nakon dodavanja flagova. Recall raste sa 0,739 na 0,745, a ROC AUC sa 0,9492 na 0,9508.

Pomaci su manji nego u regresionom primeru jer je baseline već veoma jak i početna efektivna kompletnost iznosi 98,88%. Nisu svi modeli imali korist od flagova: kod Extra Trees završni F1 ostaje 0,751 i niži je od 0,758 na očišćenoj verziji bez flagova. Ovaj nalaz je važan jer pokazuje da indikator kvaliteta treba empirijski proveriti, a ne automatski smatrati korisnim atributom.



Slika 9: F1 rizične klase za raw baseline, očišćene podatke i podatke sa quality flagovima

9.6 Diskusija praktičnih rezultata

Prvi scenario pokazuje izraženiji efekat zato što tehnika direktno vraća informacije koje određuju ciljnu agregaciju. Drugi scenario pokazuje manji, ali merljiv dobitak, uz važnu korist u transparentnosti i očuvanju porekla. Razlika potvrđuje teorijski stav da vrednost intervencije zavisi od vrste greške, zadatka i početnog kvaliteta.

Ograničenje regresionog eksperimenta je što su referentni agregati izvedeni iz oporavljene verzije, pa rezultat treba tumačiti kao demonstraciju korisnosti rekonstrukcije za taj definisani cilj. Pravila i cenovnik u strožoj produkcionoj evaluaciji treba učiti samo iz trening perioda. U klasifikacionom eksperimentu jedan train/test presek ne daje procenu statističke nesigurnosti, pa bi ponovljena ili unakrsna validacija bila poželjna.

Zajednički zaključak nije da svako čišćenje poboljšava svaki model, već da pravilno definisana tehnika može da se proveriti kroz fer poređenje sa baseline-om. Pored metrike modela potrebno je vrednovati potpunost, distribuciju, stabilnost i mogućnost objašnjenja intervencije.

10. Zaključak

Kvalitet podataka je višedimenzionalan i kontekstualan problem. Pouzdan postupak počinje definisanjem namene, nastavlja se auditom i analizom, a zatim izborom rešenja prema mehanizmu greške. Uklanjanje, imputacija, oporavak zasnovan na pravilima i indikatori kvaliteta imaju različite pretpostavke i posledice. Nijedna metoda nije univerzalno najbolja.

Raspodela, varijansa i korelacija nisu samo elementi eksplorativne analize, već kontrole koje pokazuju da li je obrada promenila statističku strukturu. Čuvanje originalnih vrednosti, flagova i dnevnika intervencija omogućava reviziju i odgovornu interpretaciju.

Praktični eksperimenti pokazuju kako se teorijske tehnike mogu primeniti u dva različita scenarija. Oporavak deterministički povezanih transakcionih atributa smanjio je grešku prognoze potražnje kod gotovo svih nelinearnih modela. Validacija, grupna imputacija i flagovi kvaliteta doneli su manji pomak u klasifikaciji rizika jer je baseline već bio jak, ali su poboljšali kompletnost i transparentnost.

Najvažnija preporuka je da se efekat obrade uvek meri u odnosu na jasno definisan baseline, uz istu podelu podataka i kontrolu curenja informacija. Kvalitet nije jednokratno čišćenje, već kontinuiran proces merenja, intervencije, provere i praćenja.

11. Literatura

- [1] Wang, R. Y., Strong, D. M. (1996). Beyond Accuracy: What Data Quality Means to Data Consumers. *Journal of Management Information Systems*, 12(4), 5–33.
- [2] Batini, C., Scannapieco, M. (2016). *Data and Information Quality: Dimensions, Principles and Techniques*. Springer.
- [3] IBM. What Is Data Quality? Dostupno na: <https://www.ibm.com/think/topics/data-quality>
- [4] Great Expectations. GX Core overview. Dostupno na: https://docs.greatexpectations.io/docs/core/introduction/gx_overview/
- [5] pandas documentation. Working with missing data. Dostupno na: https://pandas.pydata.org/docs/user_guide/missing_data.html
- [6] scikit-learn documentation. User Guide: supervised learning, preprocessing, model evaluation. Dostupno na: https://scikit-learn.org/stable/user_guide.html
- [7] XGBoost documentation. XGBoost Documentation. Dostupno na: <https://xgboost.readthedocs.io/en/stable/>
- [8] LightGBM documentation. Welcome to LightGBM's documentation. Dostupno na: <https://lightgbm.readthedocs.io/en/stable/>
- [9] CatBoost documentation. CatBoost Documentation. Dostupno na: <https://catboost.ai/docs/en/>
- [10] Kaggle. Cafe Sales - Dirty Data for Cleaning Training. Dostupno na: <https://www.kaggle.com/datasets/ahmedmohamed2003/cafe-sales-dirty-data-for-cleaning-training>
- [11] Kaggle. Credit Risk Dataset. Dostupno na: <https://www.kaggle.com/datasets/laotse/credit-risk-dataset>